

# Détection automatique de faux billets

ONCFM

Nicolas Pautet

Septembre 2025

# Contexte : objectif de l'étude

---

Mettre en place un algorithme de classification de billets

Source de données :

- Relevés de mesures géométriques sur échantillon de billets
- 1500 billets, 1000 authentiques et 500 faux


**Objectif - détecter automatiquement les faux billets :**

- Tester et évaluer la performance de modèles prédictifs
- Sélectionner et appliquer le modèle le plus performant

# Données d'entraînement

1500 billets, 7 variables :

- 6 cotes en mm
- *is\_genuine* : booléen, indique si le billet est authentique ou non  
→ **variable à prédire**



# Données manquantes

---

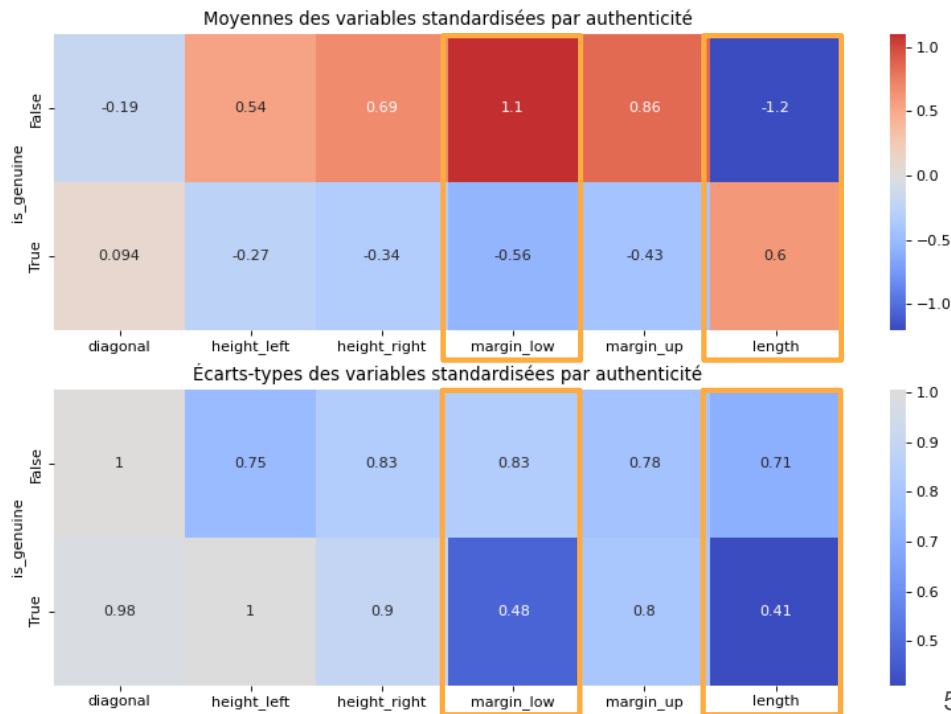
/!\ 37 billets (29 vrais et 8 faux) → 2,5% de l'échantillon pour lesquels on n'a pas la mesure *margin\_low*

Ces valeurs manquantes seront imputées par régression linéaire à partir des autres variables

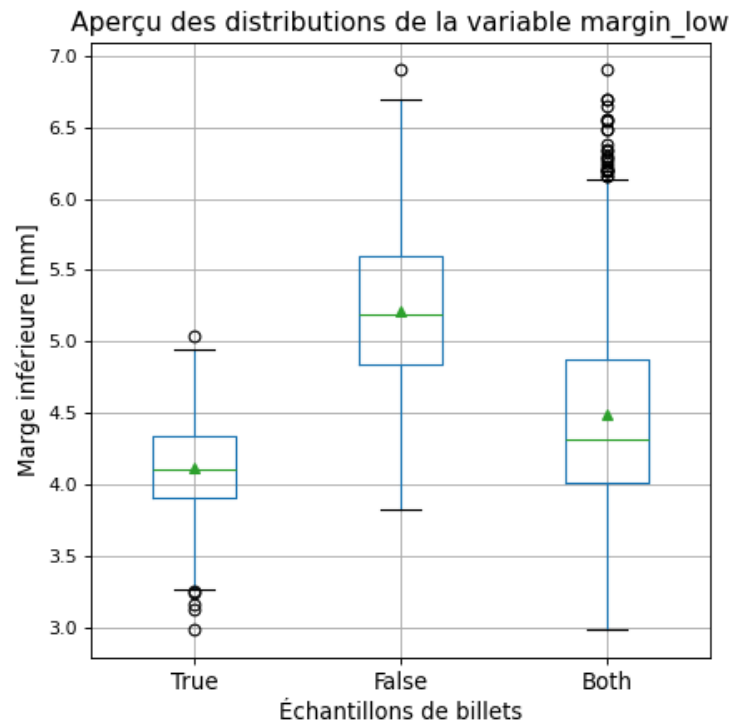

# Analyses univariées

Écarts de cotes significatifs  
entre vrais et faux billets  
pour variables *length* et  
*margin\_low*

Variance plus faible pour  
ces 2 variables sur les  
vrais billets



# Analyses univariées




# Analyse bivariée sur l'échantillon complet


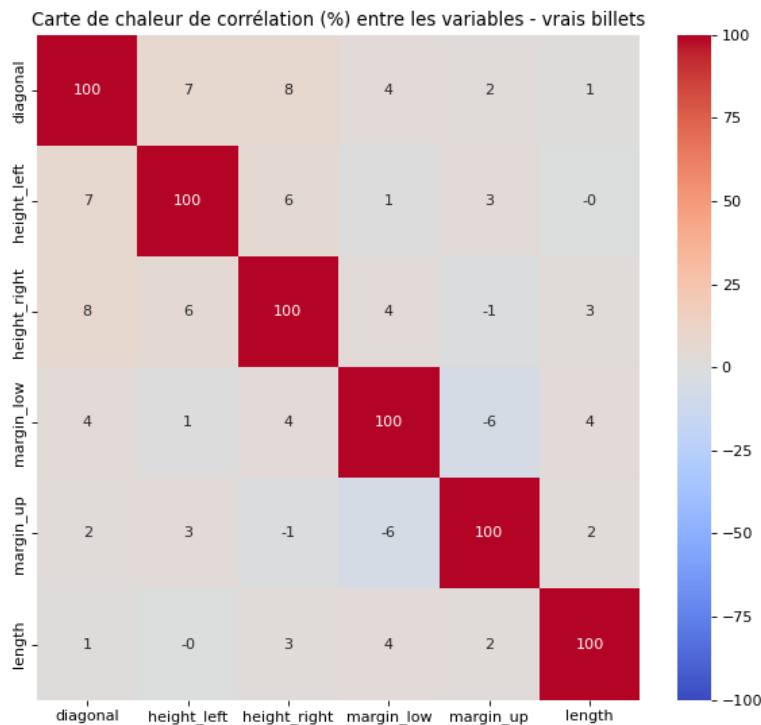
La variable *is\_genuine* a un poids considérable relativement à l'information contenue dans les données

Une fois les billets séparés selon leur authenticité, les variables semblent décorrélées

Carte de chaleur de corrélation (%) entre les variables - échantillon complet



# Analyse bivariée selon l'authenticité





# Imputation par régression linéaire

---

D'après ce qui précède, on devrait traiter séparément les vrais billets des faux billets quant à l'imputation de valeurs manquantes pour la variable *margin\_low*

Pour chaque authenticité de billets, on utilise une approche incrémentale de comparaison de modèles, afin d'établir des modèles de régression simples et statistiquement pertinents

# Démarche de comparaison de modèles

---

1. On détermine l'ordre dans lequel devraient être ajoutées une par une les variables prédictives, en fonction du score  $R^2$  des régressions associées, cela donne une suite ordonnée de modèles à tester
2. On effectue un test F comparant le modèle à  $n$  prédicteurs vs. le modèle à  $n+1$  prédicteurs, et on suit le résultat du test (rejeter le modèle  $n$  au profit du modèle  $n+1$ )
3. On peut s'arrêter dès qu'un modèle n'est pas rejeté par un test F, et on le compare à un modèle avec tous les prédicteurs possibles

# Application aux faux billets

---

- Prédiction constante vs.  $margin_{low} \sim margin_{up}$   
 $p \sim 10^{-303} \rightarrow$  modèle compact rejeté
- $margin_{low} \sim margin_{up}$  vs.  $margin_{low} \sim \{margin_{up} + diagonal\}$   
 $p \approx 0,184 \rightarrow$  modèle compact acceptable
- $margin_{low} \sim margin_{up}$  vs.  $margin_{low} \sim \{\text{tous les prédicteurs}\}$   
 $p \approx 0,486 \rightarrow$  modèle retenu validé

Le modèle retenu est :  $margin_{low} = -1,100 * margin_{up} + 6,690$   
pour lequel on a  $R^2 = 0,02$

# Application aux vrais billets

---

- Prédiction constante vs.  $margin_{low} \sim margin_{up}$   
 $p \approx 0,060 \rightarrow$  modèle compact acceptable
- $margin_{low} \sim margin_{up}$  vs.  $margin_{low} \sim \{margin_{up} + length\}$   
 $p \approx 0,210 \rightarrow$  modèle compact acceptable
- $margin_{low} \sim margin_{up}$  vs.  $margin_{low} \sim \{\text{tous les prédicteurs}\}$   
 $p \approx 0,385 \rightarrow$  modèle retenu validé

Le modèle retenu est :  $margin_{low} = -0,104 * margin_{up} + 4,434$   
pour lequel on a  $R^2 = 0,004$


# Performances de la régression

Comparaison des prédictions  $\hat{y}_k$   
avec les valeurs  $y_k$  connues :

$$MAE = \frac{1}{N} * \sum |\hat{y}_k - y_k| = 0,315 \text{ mm}$$

$$RMSE = \sqrt{\frac{1}{N} * \sum (\hat{y}_k - y_k)^2} = 0,410 \text{ mm}$$

$$MAPE = \frac{1}{N} * \sum \frac{|\hat{y}_k - y_k|}{|y_k|} = 7,0 \%$$



# Modèles prédictifs

Variable prédite : *is\_genuine*

Le billet est-il authentique ?

Prédicteurs :

Les mesures géométriques

# Métrique pour évaluer et classer les modèles

Rappel de l'objectif : **détecter en priorité les faux billets**

Vrai billet = Négatif

Faux billet = Positif

La métrique  $Rappel = \frac{VP}{VP+FN}$  (à maximiser) apparaît pertinente

Problème : prédire tout le temps que le billet est faux est optimal

On va plutôt utiliser un F-score (à maximiser) :

$$F_{score} = (1 + rc) \frac{Précision * Rappel}{rc * Précision + Rappel} \quad \text{où : } rc = \frac{\text{coût traitement FN}}{\text{coût traitement FP}} = 20$$

# Modèles testés

---

- K-Means avec 2 clusters ( $k = 2$ )
- Régression logistique avec seuil de décision à déterminer
- K-NN avec  $k$  (nombres de voisins) à déterminer
- Forêt aléatoire avec  $n$  (nombre d'arbres) à déterminer



# Principe de la validation croisée

---

Les données de test sur lesquelles on fait des prédictions doivent être indépendantes des données d'entraînement

Échantillon complet découpé en 5 *folds* de taille égale :



On fait tour à tour des **prédictions sur chaque fold** en utilisant les données des **autres folds** pour l'entraînement



On compare les valeurs prédites avec les valeurs réelles (connues)

# Performances des modèles testés

---

Résultats obtenus par validation croisée :

Nom	Valeur paramètre	F_score	Rappel	Exactitude	Précision
K-Means	2	0,976	0,976	0,986	0,982
Régression logistique	0,85	0,994	0,996	0,983	0,956
KNN	2	0,985	0,986	0,984	0,966
Forêt aléatoire	2	0,986	0,990	0,966	0,916

# Visualisation des résultats

## → Matrice de confusion

Performances de l'algorithme de régression logistique avec seuil de décision à 0,85 en validation croisée :

<u>Rappel</u> : Positif = Faux billet Négatif = Vrai billet		Valeur prédite	
		Positif	Négatif
Valeur réelle	Positif	498	2
	Négatif	23	977

# Observations et conclusion

---

Modèle retenu : régression logistique avec seuil de décision à 0,85

Les modèles présentés sont conservateurs car ils sont évalués en priorité sur leur capacité à détecter les faux billets quitte à ne pas prédire correctement des vrais billets (faux positifs)

Selon leur probabilité prédite (par exemple si  $0,5 \leq p \leq 0,85$ ), les billets testés ne seront pas toujours faux mais seront au moins suspects

Merci pour votre attention

Avez-vous des questions ?